

การพัฒนาโมเดลทำนายและวินิจฉัยความสำเร็จในการเรียนวิชาวิจัยระดับปริญญาตรี ด้วยปัญญาประดิษฐ์ที่อธิบายได้

Development of Prediction and Diagnostic Model on Academic Success in Undergraduate Research Learning Using Explainable AI

จิระเมศร์ รุจิกรหิรัญ¹ ประภาพรณ ยด้อย¹ ลีวะโชติ ศรีสุทธิยากร²

Jiramate Rujikornhirun¹ Prapapan Yodyoi¹ Siwachoat Srisuttiyakorn²

¹ นิสิตศึกษบัณฑิตสาขาวิชาสถิติและวิทยาการข้อมูลการศึกษา ภาควิชาวิจัยและจิตวิทยาการศึกษา คณะครุศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย

Ph.D. Student of Educational Statistics and Educational Data Science, Faculty of Education, Chulalongkorn University

² อาจารย์ประจำหลักสูตรสถิติและวิทยาการข้อมูลการศึกษา ภาควิชาวิจัยและจิตวิทยาการศึกษา คณะครุศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย

Lecturer of Educational Statistics and Educational Data Science, Faculty of Education, Chulalongkorn University

บทคัดย่อ

การวิจัยนี้มีวัตถุประสงค์เพื่อพัฒนาโมเดลทำนายและวินิจฉัยความสำเร็จในการเรียนวิชาวิจัยระดับปริญญาตรีด้วยการประยุกต์ใช้ปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI: XAI) เพื่อเพิ่มความโปร่งใสในการวิเคราะห์และสร้างข้อมูลย้อนกลับที่เหมาะสมสำหรับการพัฒนาการเรียนรู้ของผู้เรียน กลุ่มเป้าหมายคือ นิสิตระดับชั้นปีที่ 3-4 คณะครุศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย จำนวน 367 คน ข้อมูลที่ใช้ประกอบด้วยพฤติกรรมการเรียนรู้ คุณลักษณะของข้อสอบ และผลสัมฤทธิ์ทางการเรียนโดยใช้อัลกอริทึม 6 ตัว พัฒนาโมเดลด้วยการทำ cross validation จำนวน 5 ชุดและวนซ้ำ 3 ครั้ง ประกอบกับการปรับแต่ง hyperparameter ด้วยการทำ grid search และใช้เทคนิค XAI รูปแบบ SHAP (SHapley Additive Explanations) ในการอธิบายผลลัพธ์หรือกระบวนการตัดสินใจของโมเดล

ผลการวิจัยพบว่าโมเดล Gradient Boosting มีประสิทธิภาพสูงสุดในการทำนายความสำเร็จ โดยมีค่า ROC_AUC = .812, Accuracy = .732, Sensitivity = .730, Specificity = .733, Brier score = .176 เมื่อสร้างการอธิบายด้วยเทคนิค SHAP พบว่าปัจจัยที่มีผลต่อความสำเร็จในการเรียนมากที่สุด ได้แก่ ค่าอำนาจจำแนกของข้อสอบ (IRT Discrimination) ค่าความยากของข้อสอบ (IRT Difficulty) คะแนนสอบกลางภาคด้านการออกแบบการวิจัย (ResDesignMid) ผลลัพธ์การเรียนรู้ (LearningOutcome) และคะแนนสอบกลางภาควิชาสถิติ (StatMidterm) เมื่อนำค่าทำนายและค่าผลกระทบที่ได้จากโมเดลมาใช้จัดกลุ่มผู้เรียนเพื่อวินิจฉัยความสำเร็จในการเรียนสามารถแบ่งกลุ่มผู้เรียนได้ 3 กลุ่ม ได้แก่ 1) กลุ่มที่มีแนวโน้มความสำเร็จสูง (High-Probability Success Group: HPSG) 2) กลุ่มที่มีแนวโน้มความสำเร็จปานกลาง (Moderate-Probability Success Group: MPSG) และ 3) กลุ่มที่มีโอกาสในการพัฒนา (Growth-Opportunity Group: GOG) เพื่อช่วยระบุผู้เรียนที่ต้องการความช่วยเหลือในด้านต่าง ๆ และปรับปรุงการจัดการเรียนการสอนให้ตรงจุด อีกทั้งยังสามารถสร้างสารสนเทศเป็นรายบุคคลเพื่อช่วยให้สามารถประเมินผลกระทบของปัจจัยที่แตกต่างกันต่อโอกาสสำเร็จของผู้เรียนในข้อสอบแต่ละข้อได้ นอกจากนี้สามารถสะท้อนถึงการวัดประเมินผลในแต่ละผลลัพธ์การเรียนรู้โดยแบ่งเป็นชุดข้อสอบ 3 รูปแบบ ได้แก่ ระดับง่าย ปานกลาง และยาก แสดงให้เห็นถึงศักยภาพของการใช้ XAI ในการสนับสนุนการตัดสินใจของผู้สอนและการพัฒนาการเรียนรู้เฉพาะบุคคล โดยสามารถนำไปพัฒนาระบบการเรียนการสอนและระบบแจ้งเตือนผู้เรียนในอนาคตได้อย่างมีประสิทธิภาพ

คำสำคัญ: ความสำเร็จในการเรียน ปัญญาประดิษฐ์ที่อธิบายได้ การเรียนรู้เฉพาะบุคคล การวิเคราะห์การเรียนรู้

Abstract

This study aimed to develop predictive and diagnostic models for academic success in undergraduate research courses by applying Explainable Artificial Intelligence (XAI) to enhance transparency in analysis and provide actionable feedback for improving student learning. The target group consisted of 367 third- and fourth-year undergraduate students from the Faculty of Education, Chulalongkorn University. The dataset included learning behaviors, test item characteristics, and academic performance. Six algorithms were employed to develop the models using 5-fold cross-validation repeated 3 times, with hyperparameter tuning performed via Grid Search. The SHAP (SHapley Additive Explanations) technique was applied to interpret the model's outputs and decision-making processes.

The findings revealed that the Gradient Boosting model achieved the highest predictive performance, with ROC_AUC = .812, Accuracy = .732, Sensitivity = .730, Specificity = .733, Brier score = .176. SHAP analysis indicated that the most influential factors contributing to academic success included the discrimination index of test items (IRT Discrimination), midterm scores in research design (ResDesignMid), and midterm scores in statistics (StatMidterm). The predictive values and SHAP-derived feature impacts were used to classify students into three groups: (1) High-Probability Success Group (HPSG), (2) Moderate-Probability Success Group (MPSG), and (3) Growth-Opportunity Group (GOG). These classifications help identify students requiring targeted support and enable the refinement of instructional strategies to address specific needs.

Additionally, individualized insights were generated to evaluate the influence of various factors on the likelihood of success for each test item. This approach also highlighted learning outcome assessments through the classification of test items into three levels: easy, moderate, and difficult. The results demonstrate the potential of XAI in supporting instructors' decision-making and fostering personalized learning development. This research could inform the development of instructional systems and early warning systems for students, enhancing the effectiveness of teaching and learning processes in the future.

KEYWORDS: Academic Success Explainable Artificial Intelligence Personalized Learning Learning Analytics

บทนำ

ในยุคที่เทคโนโลยีมีบทบาทสำคัญในระบบการศึกษา การเรียนรู้ที่สนับสนุนศักยภาพเฉพาะบุคคล (Personalized Learning) ได้รับความสนใจอย่างแพร่หลาย เนื่องจากสามารถตอบสนองความต้องการและความสามารถของผู้เรียนแต่ละคนได้อย่างมีประสิทธิภาพ ลักษณะเด่นของ Personalized Learning คือ ผู้สอนจะต้องออกแบบการเรียนรู้ที่ปรับเปลี่ยนให้แตกต่างตาม พื้นฐาน ความต้องการ และความสนใจ ของผู้เรียน โดยยังคงรักษามาตรฐานการเรียนรู้ตามที่กำหนด องค์ประกอบหลักของ Personalized Learning ได้แก่ การรับรู้และวิเคราะห์ความต้องการของผู้เรียน การใช้ข้อมูลและสารสนเทศเพื่อสนับสนุนการตัดสินใจ การสร้างสภาพแวดล้อมที่เอื้อต่อการเรียนรู้ การส่งเสริมการเรียนรู้ร่วมกันและความร่วมมือ และการพัฒนาทักษะการคิดวิเคราะห์และการแก้ปัญหา (OECD, 2018; สำนักงานส่งเสริมเศรษฐกิจดิจิทัล, 2565)

ถึงแม้ในเชิงทฤษฎี Personalized Learning จะมีศักยภาพสูงในการเพิ่มประสิทธิภาพการเรียนรู้ของผู้เรียน (Kaur et al., 2022; Pane et al., 2015) แต่การนำแนวคิดดังกล่าวมาใช้ในการจัดการเรียนรู้ของรายวิชาการวิจัยระดับปริญญาบัณฑิตของนิสิตคณะครุศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย ยังคงมีข้อจำกัดเนื่องจากรายวิชาดังกล่าวเป็นรายวิชาที่มีขนาดชั้นเรียนใหญ่ มีนิสิตจำนวนกว่า 300 คนต่อภาคการศึกษา การติดตามความก้าวหน้าและการประเมินผู้เรียนระหว่างการเรียนรู้เป็นรายบุคคลเพื่อนำไปสู่การออกแบบกิจกรรม ความช่วยเหลือ หรือการสนับสนุนที่เหมาะสมให้กับนิสิตเฉพาะบุคคลโดยตัวผู้สอนเอง จึงเป็นเรื่องที่ต้องใช้เวลาและเป็นภาระที่ค่อนข้างมาก สภาพดังกล่าวแสดงให้เห็นว่าการบริหารจัดการในรายวิชาที่มีปัญหาทั้งในด้านการรับรู้และวิเคราะห์ความต้องการของผู้เรียน การใช้ข้อมูลและสารสนเทศเพื่อสนับสนุนการตัดสินใจ ส่งผลให้การจัดการเรียนรู้ในรายวิชาตามแนวคิด Personalized Learning ทำได้อย่างจำกัด ล้าช้าและไม่ทั่วถึง

การแก้ปัญหาดังกล่าวจำเป็นต้องอาศัยเครื่องมือที่สามารถวิเคราะห์และทำนายความสามารถของผู้เรียนในระดับที่ละเอียดและเฉพาะเจาะจง ไม่ว่าจะเป็นการทำนายความสามารถรายข้อสอบ หรือรายผลลัพธ์การเรียนรู้ (Learning Outcome) เนื่องจากการให้ข้อมูลป้อนกลับที่มีประสิทธิภาพจำเป็นต้องระบุจุดแข็งและจุดที่ต้องพัฒนาของผู้เรียนได้อย่างชัดเจน การให้ข้อมูลป้อนกลับในภาพรวมเพียงอย่างเดียว เช่น คะแนนรวมหรือเกรด อาจไม่เพียงพอต่อการพัฒนาผู้เรียนอย่างมีประสิทธิภาพ โดยเฉพาะในรายวิชาการวิจัยที่มีความซับซ้อนและประกอบด้วยทักษะย่อยหลายด้าน การวินิจฉัยความสามารถในระดับย่อยจะช่วยให้ผู้สอนสามารถให้คำแนะนำและความช่วยเหลือที่ตรงจุดกับผู้เรียนแต่ละคน อันจะนำไปสู่การพัฒนาการเรียนรู้แบบเฉพาะบุคคลที่มีประสิทธิภาพมากขึ้น

เพื่อแก้ไขข้อจำกัดดังกล่าวการวิจัยนี้จึงนำการเรียนรู้ของเครื่อง (Machine Learning) มาใช้เป็นเครื่องมือสำคัญในการสร้างสารสนเทศที่จำเป็นเพื่อสนับสนุนการจัดการเรียนรู้แบบ Personalized Learning แบบอัตโนมัติ ได้แก่ การพัฒนาระบบแจ้งเตือนล่วงหน้า (early warning system) ที่ใช้ระบุว่านิสิตคนใดมีแนวโน้มที่ต้องการความช่วยเหลือเพิ่มเติมโดยอัตโนมัติ ระบบนี้ช่วยให้ผู้สอนสามารถติดตามแนวโน้มผลการเรียนและวิเคราะห์ความเสี่ยงของนิสิตแต่ละคนได้อย่างแม่นยำ ซึ่งสามารถนำไปสู่การแจ้งเตือนผู้เรียนและดำเนินการวิเคราะห์เชิงลึกถึงปัจจัยที่อาจส่งผลต่อการเรียนของนิสิตและใช้สารสนเทศดังกล่าวเพื่อออกแบบการเรียนรู้หรือความช่วยเหลือที่เหมาะสมกับนิสิตแต่ละบุคคลได้อย่างทันท่วงที

การออกแบบการเรียนรู้หรือความช่วยเหลือที่เหมาะสมจำเป็นต้องอาศัยสารสนเทศที่ชี้ให้เห็นถึงปัจจัยที่เป็นอุปสรรคหรือสนับสนุนการเรียนรู้ของผู้เรียนแต่ละบุคคล การได้มาซึ่งสารสนเทศดังกล่าวจะต้องวิเคราะห์ข้อมูลด้วยการเรียนรู้ของเครื่อง (Gašević et al., 2015; Baker & Inventado, 2014) อย่างไรก็ตามแม้โมเดลการเรียนรู้ของเครื่อง (Machine Learning) ส่วนใหญ่จะสามารถทำนายผลได้อย่างแม่นยำแต่กลับมีข้อจำกัดในการอธิบายกระบวนการตัดสินใจและปัจจัยที่นำไปสู่ผลลัพธ์ ข้อจำกัดนี้เกิดจากโมเดลทำนายส่วนมากทำงานในลักษณะของกล่องดำ (Black Box) ที่ให้ผลลัพธ์แต่ไม่สามารถอธิบายหรือให้เหตุผลที่ชัดเจนว่าทำไมจึงได้ผลลัพธ์ดังกล่าว ซึ่งทำให้ขาดความโปร่งใสในกระบวนการวิเคราะห์ส่งผลต่อความเชื่อมั่นในการนำโมเดลไปใช้งาน นอกจากนี้ยังทำให้การนำผลลัพธ์ไปใช้ต่อยอดยังทำได้ไม่เต็มที่ เนื่องจากผู้สอนไม่สามารถระบุได้ว่าปัจจัยใดที่มีผลต่อค่าทำนายความสำเร็จหรือความเสี่ยงในการเรียนของผู้เรียนแต่ละคนมากที่สุด

ปัจจุบันมีการเสนอแนวคิดปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI: XAI) ที่เกี่ยวข้องกับเทคนิคที่ช่วยให้สามารถอธิบายผลลัพธ์หรือกระบวนการตัดสินใจของโมเดลการเรียนรู้ของเครื่องได้อย่างชัดเจน เข้าใจง่าย เพิ่มความโปร่งใส และความน่าเชื่อถือในการใช้งาน ตัวอย่างของเทคนิค XAI เช่น SHAP (SHapley Additive Explanations) ที่แสดงให้เห็นว่าตัวแปรใดมีผลต่อการทำนายมากที่สุดและ LIME (Local Interpretable Model-agnostic Explanations) ที่ช่วยสร้างโมเดลย่อยเพื่ออธิบายการทำงานของโมเดลหลัก (Holzinger et al., 2022; Molnar, 2020) การนำ XAI เข้ามาประยุกต์ใช้ร่วมกับระบบแจ้งเตือนล่วงหน้าจึงช่วยให้ผู้สอนสามารถวิเคราะห์ปัจจัยที่ส่งผลต่อการเรียนรู้ได้ในเชิงลึก สามารถทำความเข้าใจได้ว่าผู้เรียนมีจุดที่ควรพัฒนาในด้านใด ซึ่งทำให้ผู้สอนสามารถให้คำปรึกษา ออกแบบหรือดำเนินการช่วยเหลือนิสิตแต่ละบุคคลได้อย่างตรงจุดมากขึ้น ตอบสนองแนวคิด Personalized Learning ได้อย่างมีประสิทธิภาพ

วัตถุประสงค์

1. เพื่อพัฒนาโมเดลการทำนายความสำเร็จในการเรียนของผู้เรียนด้วยพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบผ่านเทคนิคการเรียนรู้ของเครื่อง
2. เพื่อวิเคราะห์ปัจจัยด้านพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบที่ส่งผลต่อความสำเร็จในการเรียนในระดับภาพรวมและรายบุคคลโดยอาศัยปัญญาประดิษฐ์ที่อธิบายได้

วิธีดำเนินการวิจัย

กลุ่มเป้าหมาย

การวิจัยนี้มีกลุ่มเป้าหมาย คือ นิสิตระดับชั้นปีที่ 3-4 คณะครุศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย ที่ลงทะเบียนเรียนในรายวิชาการวิจัยเพื่อพัฒนาการเรียนรู้

ข้อมูลและการเก็บรวบรวมข้อมูล

การวิจัยนี้ใช้ข้อมูลของนิสิตที่ลงทะเบียนในรายวิชาการวิจัยเพื่อพัฒนาการเรียนรู้ ภาคปลาย ปีการศึกษา 2566 จำนวน 367 คน ประกอบด้วยข้อมูลภูมิหลัง พฤติกรรมการเรียนรู้ และผลสอบปลายภาคในรายวิชาตาม Table 1

Table 1 ความหมายและค่าของตัวแปรที่ใช้ในการพัฒนาโมเดล

ตัวแปร	ความหมาย	ค่าของตัวแปร
Response	ผลการตอบข้อสอบปลายภาค	ค่าเป็น 1 หมายถึง ตอบถูก ค่าเป็น 0 หมายถึง ตอบผิด
Department	สาขาวิชาที่นิสิตสังกัด	ชื่อสาขาวิชา 13 สาขา
Item	เลขข้อของข้อสอบปลายภาควิชาวิจัย	หมายเลขข้อสอบ 1-80 ข้อ
LearningOutcome	ผลลัพธ์การเรียนรู้	หมวดหมู่ผลลัพธ์การเรียนรู้ 6 ด้าน
IRTDifficulty	ค่าความยากของข้อสอบ	ค่า 0.0 ถึง 1.0
IRTDiscrimination	ค่าอำนาจจำแนกของข้อสอบ	ค่า -1.0 ถึง 1.0
ResConceptMid	คะแนนสอบกลางภาคด้านความรู้พื้นฐาน	ร้อยละ 0 – 100
ResDesignMid	คะแนนสอบกลางภาคด้านหลักการออกแบบวิจัย	ร้อยละ 0 – 100
ResMeasureMid	คะแนนสอบกลางภาคด้านการสร้างเครื่องมือวัด	ร้อยละ 0 – 100
ResProposeMid	คะแนนสอบกลางภาคด้านการเขียนโครงร่างวิจัย	ร้อยละ 0 – 100
ChooseMethod	คะแนนความรู้ด้านการเลือกใช้เครื่องมือในการวิเคราะห์ข้อมูล	คะแนน 0 - 100
Critical	คะแนนการวิพากษ์งานวิจัย	คะแนน 0 - 100
Concepts	คะแนนความรู้พื้นฐานทางสถิติ	คะแนน 0 - 100
Interpretation	คะแนนความรู้การตีความผลการวิเคราะห์	คะแนน 0 - 100
SubmitTime	ระยะเวลาที่ใช้ทำงาน	Ontime หมายถึง ส่งภายในเวลาที่กำหนด Late หมายถึง ส่งหลังจากเวลาที่กำหนด
PrecentSubmit	ร้อยละของจำนวนงานที่ได้รับมอบหมาย	ร้อยละ 0 - 100

ตัวแปร	ความหมาย	ค่าของตัวแปร
LearnPerform	คะแนนพฤติกรรมการเรียนรู้	คะแนน 0 – 100
CheatBehavior	พฤติกรรมในการทุจริต	ดัชนี 0 - 1
StatParticipation	คะแนนการมีส่วนร่วมในชั้นเรียนวิชาสถิติ	คะแนน 0 – 100
StatAssignment	คะแนนการส่งงานในชั้นเรียนวิชาสถิติ	คะแนน 0 – 100
StatMidterm	คะแนนสอบกลางภาคในชั้นเรียนวิชาสถิติ	คะแนน 0 – 100

ผลการวิจัย

ผลการวิจัยจำแนกออกเป็น 3 ส่วน ได้แก่ 1) ผลการสำรวจข้อมูลพฤติกรรมการเรียนรู้ คุณลักษณะของข้อสอบ และผลสัมฤทธิ์ทางการเรียนของผู้เรียน 2) ผลการพัฒนาโมเดลการทำนายความสำเร็จในการเรียนของผู้เรียนด้วยพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบโดยใช้การเรียนรู้ของเครื่อง 3) ผลการวิเคราะห์ปัจจัยด้านพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบที่ส่งผลต่อความสำเร็จในการเรียนในระดับภาพรวมและรายบุคคลด้วยปัญญาประดิษฐ์ที่อธิบายได้รายละเอียดดังนี้

1. ผลการสำรวจข้อมูลพฤติกรรมการเรียนรู้ คุณลักษณะของข้อสอบ และผลสัมฤทธิ์ทางการเรียนของผู้เรียน

จากการสำรวจข้อมูลทั่วไปของผู้เรียนพบว่าผู้เรียนในแต่ละสาขาวิชามีจำนวนใกล้เคียงกันดังรายละเอียดใน Table 2 เมื่อพิจารณาผลการตอบข้อสอบปลายภาคใน Figure 1 พบว่าผู้เรียนส่วนใหญ่สามารถตอบข้อปลายภาคได้ถูกต้อง (ค่าเฉลี่ย = 58.5, ส่วนเบี่ยงเบนมาตรฐาน = 0.49) โดยข้อสอบปลายภาคมีจำนวนทั้งสิ้น 80 ข้อ แบ่งตามผลลัพธ์การเรียนรู้ที่คาดหวัง 6 ด้าน ดัง Table 3 พบว่ามีสัดส่วนของจำนวนข้อแตกต่างกัน โดยด้านการวิเคราะห์และเขียนรายงานมีจำนวนข้อสูงที่สุด คิดเป็นร้อยละ 40 รองลงมาเป็นด้านเครื่องมือและการเก็บข้อมูล คิดเป็นร้อยละ 16.25




Figure 1 ร้อยละการกระจายของอัตราการตอบของข้อสอบ

จาก Table 3 เมื่อพิจารณาพฤติกรรมการเรียนรู้ พบว่า ผู้เรียนมีพฤติกรรมการเรียนค่อนข้างดี (LearnPerform) (ค่าเฉลี่ย = 77.46, ส่วนเบี่ยงเบนมาตรฐาน = 11.57) มีความรับผิดชอบ (PercentSubmit) (ค่าเฉลี่ย = 92.87, ส่วนเบี่ยงเบนมาตรฐาน = 11.81) มีส่วนร่วมในชั้นเรียน (StatParticipation) (ค่าเฉลี่ย = 4.66, ส่วนเบี่ยงเบนมาตรฐาน = 0.49) ทำแบบฝึกหัดอย่างสม่ำเสมอ (ค่าเฉลี่ย = 4.43, ส่วนเบี่ยงเบนมาตรฐาน = 0.81) และส่งงานทันเวลา (SubmitTime) คิดเป็นร้อยละ 91.55 แต่ยังพบผู้เรียนที่มีพฤติกรรมในการทุจริต (CheatBehavior) (ค่าเฉลี่ย = 0.78, ส่วนเบี่ยงเบนมาตรฐาน = 0.18) เมื่อพิจารณาผลสัมฤทธิ์ทางการเรียนพบว่า ผู้เรียนส่วนใหญ่มีความรู้เกี่ยวกับสถิติและสารสนเทศในระดับปานกลาง พิจารณาค่าเฉลี่ยของ ChooseMethod, Concepts, Interpret มีค่าอยู่ในช่วง 37-45 คะแนน (ค่าเฉลี่ย = 37.79, 45.76, 43.72 ส่วนเบี่ยงเบนมาตรฐาน = 16.51, 16.50, 15.63) และมีความรู้พื้นฐานด้านการวิจัยในระดับปานกลาง พิจารณาค่าเฉลี่ยของ ResConceptMid, ResDesignMid, ResMeasureMid และ ResProposeMid มีค่าสัดส่วนคะแนนอยู่ในช่วง 0.54-0.62 (ค่าเฉลี่ย = 0.54, 0.59, 0.62, 0.58 ส่วนเบี่ยงเบนมาตรฐาน = 0.14, 0.14, 0.18, 0.13)

Table 2 จำนวนผู้เรียนที่ลงทะเบียนเรียนรายวิชาวิจัยฯ แยกตามสาขาวิชา

ตัวแปร	จำนวน	ร้อยละ
Department		
- คณิตศาสตร์	44	11.99
- วิทยาศาสตร์	38	10.35
- ไทยสังคม	37	10.08
- ศิลปศึกษา	37	10.08
- จิตวิทยาการปรึกษา	30	8.17
- ประถมศึกษา	30	8.17
- การศึกษานอกระบบ	26	7.08
- ธุรกิจและอาชีพ	25	7.08
- อื่น ๆ	100	27.25

Table 2 จำนวนข้อสอบในผลลัพธ์การเรียนรู้

ตัวแปร	จำนวน	ร้อยละ
LearningOutcome		
- มโนทัศน์พื้นฐานการวิจัย	11	13.75
- การออกแบบการวิจัย	11	13.75
- เครื่องมือและการเก็บข้อมูล	13	16.25
- การวิเคราะห์และเขียนรายงาน	32	40.00
- การเขียนและพัฒนาโครงการวิจัย	5	6.25
- การประเมินคุณภาพงานวิจัย	8	10.00

Table 3 การกระจายของตัวแปรพฤติกรรมและผลลัพธ์การเรียนรู้

ตัวแปร	ค่าเฉลี่ย	ส่วนเบี่ยงเบนมาตรฐาน	ความเบ้	ความโด่ง
ResConceptMid	0.54	0.14	-0.04	-0.32
ResDesignMid	0.59	0.14	-0.02	-0.43
ResMeasureMid	0.62	0.18	-0.24	-0.46
ResProposeMid	0.58	0.13	-0.19	0.26
ChooseMethod	37.79	16.51	0.28	-0.12
Concepts	45.76	16.50	0.08	-0.42
Interprete	43.72	15.63	-1.33	0.14
PrecentSubmit	92.87	11.81	-2.04	4.33
LearnPerform	77.46	11.57	-0.81	0.74
CheatBehavior	0.78	0.18	-0.57	-0.58
StatCritical	4.68	0.85	-3.11	10.46

ตัวแปร	ค่าเฉลี่ย	ส่วนเบี่ยงเบนมาตรฐาน	ความเบ้	ความโด่ง
StatParticipate	4.66	0.49	-1.80	3.88
StatMidterm	14.92	3.24	-0.13	-0.53
IRTDiscrimination	-0.71	2.11	-0.21	0.89
IRTDifficulty	-0.21	5.87	-5.15	36.77

2. ผลพัฒนาโมเดลการทำนายความสำเร็จในการเรียนของผู้เรียนด้วยพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบโดยใช้การเรียนรู้ของเครื่อง

เมื่อพิจารณาความสัมพันธ์ระหว่างตัวแปรในภาพรวมพบว่าตัวแปรส่วนใหญ่มีความสัมพันธ์กันในระดับปานกลาง ส่วนความสัมพันธ์ระหว่างตัวแปรทำนายกับตัวแปรตาม (Response) พบว่าส่วนใหญ่มีความสัมพันธ์ในระดับต่ำถึงปานกลาง โดยตัวแปร IRTDiscrimination มีความสัมพันธ์กับตัวแปรตามมากที่สุด รองลงมา ได้แก่ StatMidterm, ResDesignMid, ResConceptMid และ ResProposeMid ตามลำดับ Figure 2




Figure 2 heatmap แสดงระดับความสัมพันธ์ของตัวแปรในชุดข้อมูล

ผลการวิเคราะห์โมเดลคู่แข่งจำนวน 6 โมเดล ได้แก่ Elastic net logistic regression, Random forest, Linear Support Vector Machine, Radial basis function Support Vector Machine, Gradient Boosting และ Neural Network วัดประสิทธิภาพภายในชุดข้อมูลเรียนรู้ (Train dataset) ด้วย Evaluation Metrics 5 ชนิด ได้แก่ ROC_AUC, Accuracy, Sensitivity, Specificity และ Brier score พบว่า โมเดล Gradient Boosting มีประสิทธิภาพในการทำนายสูงสุด (ROC_AUC = .812, Accuracy = .732, Sensitivity = .730, Specificity = .733, Brier score = .176) รายละเอียดดัง Table 4

Table 4 ประสิทธิภาพการทำนายของโมเดลทำนาย

Rank	Model type	ROC_AUC	Accuracy	Sensitivity	Specificity	Brier score
1	Gradient Boosting	.812	.732	.730	.733	.176
2	RBF Support Vector Machine	.809	.730	.746	.719	.179
3	Elastic net logistic regression	.806	.730	.727	.732	.179
4	Linear Support Vector Machine	.806	.729	.740	.721	.180
5	Neural Network	.800	.728	.651	.782	.188
6	Random forest	.801	.725	.698	.742	.191

จากผลการเปรียบเทียบประสิทธิภาพพบว่าโมเดล Gradient Boosting มีความสามารถทำนายความสำเร็จในการเรียนของผู้เรียนได้อย่างแม่นยำและมีประสิทธิภาพค่อนข้างสูง เมื่อพิจารณารายละเอียดของการพัฒนาโมเดล พบว่า โมเดล Gradient Boosting มีการปรับ hyperparameter ในโมเดล จำนวน 8 ค่าได้แก่ 1) mtry (number of features to consider at each split) มีค่าเท่ากับ 6 หมายถึง โมเดลเลือกตัวแปรมาใช้ในการแยกข้อมูล (split) ในแต่ละต้นไม้จำนวน 6 ตัวแปร 2) trees (number of trees) มีค่าเท่ากับ 500 หมายถึง โมเดลมีต้นไม้ จำนวน 500 ต้น 3) min_n (minimum number of observations per node) มีค่าเท่ากับ 26 หมายถึง ตัวอย่างขั้นต่ำที่ใช้ในโมเดลมีจำนวน 26 ตัวอย่าง 4) tree_depth (maximum depth of the tree) มีค่าเท่ากับ 10 หมายถึง ต้นไม้แต่ละต้นมีความลึกที่สุดเป็น 10 5) learn_rate (Learning Rate) มีค่าเท่ากับ 0.033 หมายถึง โมเดลใช้ความเร็วในการอัปเดตค่าระหว่างการเรียนรู้ค่อนข้างช้า เนื่องจากข้อมูลค่อนข้างซับซ้อน 6) loss_reduction (minimum gain for a split) มีค่าเท่ากับ 11.46 หมายถึง โมเดลมีเกณฑ์ขั้นต่ำสำหรับการแยก node ใหม่ระดับปานกลาง 7) sample_size (subsampling proportion) มีค่าเท่ากับ 0.91 หมายถึง โมเดลสุ่มเลือกข้อมูลมาใช้ในการสร้างต้นไม้แต่ละต้นใกล้เคียงกับการใช้ข้อมูลทั้งหมด 8) stop_iter (stopping iterations for early stopping) มีค่าเท่ากับ 17 หมายถึง โมเดลไม่พัฒนาค่าความผิดพลาด (error) ก่อนหยุดการเรียนรู้ที่ 17 รอบ แสดงให้เห็นว่า โมเดล Gradient Boosting มีความซับซ้อนในการวิเคราะห์

3. ผลการวิเคราะห์ปัจจัยด้านพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบที่ส่งผลต่อความสำเร็จในการเรียนในระดับภาพรวมและรายบุคคลด้วยปัญญาประดิษฐ์ที่อธิบายได้

3.1 ผลการวิเคราะห์ปัจจัยด้านพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบที่ส่งผลต่อความสำเร็จในการเรียนในระดับภาพรวมด้วยปัญญาประดิษฐ์ที่อธิบายได้

จากผลการเปรียบเทียบโมเดลในข้างต้น พบว่าโมเดล Gradient Boosting มีความสามารถทำนายความสำเร็จในการเรียนของผู้เรียนได้อย่างแม่นยำและมีประสิทธิภาพค่อนข้างสูง แต่เมื่อต้องการนำผลการทำนายมาวิเคราะห์อิทธิพลของพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบที่ส่งผลต่อความสำเร็จในการเรียนพบว่าสารสนเทศจากการทำนายของโมเดล Gradient Boosting นั้นนำเสนอสารสนเทศออกมาอธิบายได้ยากและไม่ได้อยู่ในลักษณะของสมการเชิงเส้น อาจต้องใช้เทคนิคการอธิบายและตีความการทำนายของโมเดลด้วย Explainable AI เมื่อพิจารณาลำดับความสำคัญของตัวแปรหรือ Feature importance ที่ได้จากโมเดล พบว่าตัวแปรที่มีความสำคัญทำนายความสำเร็จในการเรียนของผู้เรียนมากที่สุด คือ IRTDiscrimination และ ResDesignMid รองลงมาเป็น StatMidterm, Objective และ ResMeasureMid ตามลำดับ ดัง Figure 3




Figure 3 Feature importance ในการทำนายความสำเร็จในการเรียนของโมเดล Gradient Boosting




Figure 4 แสดงระดับค่าทำนายความสำเร็จในการเรียน
ของผู้เรียนรายบุคคลแยกตามข้อสอบ

นอกจากนี้เทคนิค Explainable AI ให้สารสนเทศการมีส่วนร่วม (Contribution) ซึ่งสะท้อนผลกระทบของแต่ละปัจจัยที่ส่งผลเพิ่มหรือลดค่าทำนายของโมเดล สามารถนำสารสนเทศดังกล่าววิเคราะห์จัดกลุ่มผู้เรียนภายใต้ผลลัพธ์การเรียนรู้เดียวกัน โดยการนำ contribution ของผู้เรียนแต่ละคนในทุก ๆ ผลลัพธ์การเรียนรู้มาวิเคราะห์เพื่อลดมิติของข้อมูลด้วยการวิเคราะห์องค์ประกอบ (PCA) โดยลดมิติของคุณลักษณะต่าง ๆ ในโมเดลโดยแบ่งออกเป็น 2 องค์ประกอบ Figure 5 โดยที่องค์ประกอบแรก (แถบสีแดง) พบว่า มีค่า loadings สูงสุดในตัวแปรที่เกี่ยวข้องกับผลการเรียนและภูมิหลังของผู้เรียน เช่น




Figure 6 กลุ่มของผู้เรียนจำแนกตามค่า Contribution

โดยในแต่ละกลุ่มจะมีผลกระทบของแต่ละปัจจัยแตกต่างกัน ในภาพรวมผู้เรียนกลุ่ม HPSG จะมีผลกระทบของแต่ละปัจจัยด้านต่าง ๆ ในทางบวก เช่น StatMidterm, ResDesignMid, ResConceptMid, ResMeasureMid หมายถึง พฤติกรรมในการเรียนรู้ สัดส่วนคะแนนสอบกลางภาคส่งผลให้ผู้เรียนกลุ่มนี้มีโอกาสสำเร็จการเรียนรู้มากขึ้น ในขณะที่ผู้เรียนกลุ่ม GOG จะได้รับผลกระทบทางลบจากปัจจัยด้านต่าง ๆ เช่น StatMidterm, ResDesignMid ซึ่งหมายถึงพฤติกรรมในการเรียนรู้

นอกจากนี้สารสนเทศที่ได้จากการทำนาย เช่น ค่าทำนายในการตอบข้อสอบของผู้เรียนรายบุคคลรายข้อสามารถใช้วิเคราะห์จัดกลุ่มเพื่อสรุปสารสนเทศในภาพรวมทั้งด้านผู้เรียนและด้านข้อสอบ ซึ่งแสดงระดับค่าทำนายความสำเร็จของผู้เรียนรายบุคคลโดยใช้ระดับความเข้มของสีเพื่อแสดงค่าต่าง ๆ ตั้งแต่สีแดง (ต่ำ) ไปจนถึงสีน้ำเงิน (สูง) พร้อมทั้งมีการจัดกลุ่มแบบลำดับขั้น (Hierarchical Clustering) เพื่อแสดงโครงสร้างความสัมพันธ์ทั้งในมิติของข้อสอบและตัวผู้เรียน ตามลำดับดัง Figure 4 โดยอาจแบ่งกลุ่มผู้เรียนได้ สามารถแยกได้เป็น 3 กลุ่มหลัก ได้แก่ ผู้เรียนที่มีผลลัพธ์สูง ปานกลาง และต่ำ




Figure 5 คำนวณน้ำหนักองค์ประกอบของ contribution ของตัวแปร

StatMidterm, ResDesignMid, ResMeasureMid และ Department สะท้อนถึงความสามารถทางวิชาการโดยรวมของนักศึกษา สำหรับองค์ประกอบที่ 2 (แถบสีฟ้า) มีค่า loadings สูงในตัวแปร MeanDifficulty และ LearningOutcome สะท้อนให้เห็นถึงองค์ประกอบที่เกี่ยวข้องกับคุณลักษณะของแบบสอบ จากการวิเคราะห์ดังกล่าวทำให้สามารถจำแนกผู้เรียนออกเป็น 3 กลุ่ม ได้แก่ 1) กลุ่มที่มีแนวโน้มความสำเร็จสูง (HPSG) 2) กลุ่มที่มีแนวโน้มความสำเร็จปานกลาง (MPSG) และ 3) กลุ่มที่มีโอกาสในการพัฒนา (GOG) ดัง Figure 6

ภาคส่งผลให้ผู้เรียนกลุ่มนี้มีโอกาสสำเร็จการเรียนรู้ลดลง ส่วนผู้เรียนกลุ่ม MPSPG จะมีผลกระทบทั้งด้านบวกและลบ โดยพบปัจจัยด้านข้อสอบ ได้แก่ LearningOutcome และ MeanDiscrimination ที่ส่งผลกระทบด้านลบ หมายถึง ผลลัพธ์การเรียนรู้และอำนาจจำแนกของข้อสอบส่งผลให้ผู้เรียนกลุ่มนี้มีโอกาสสำเร็จการเรียนรู้ลดลง ส่วนผลกระทบจากปัจจัยภูมิหลัง เช่น ภาควิชาที่ผู้เรียนสังกัดมีผลต่อผู้เรียนทั้งสามกลุ่มไม่ต่างกัน รวมถึงพฤติกรรมการเรียนรู้และคะแนนจากรายวิชาสถิติและสารสนเทศทางการศึกษาดัง Figure 7




Figure 7 ระดับผลกระทบต่อความสำเร็จในการเรียนของผู้เรียนที่เกิดจากปัจจัยด้านต่าง ๆ แยกตามกลุ่ม ซึ่งเมื่อพิจารณาแยกรายผลลัพธ์การเรียนรู้ พบว่าผู้เรียนแต่ละกลุ่มมีผลกระทบจากปัจจัยต่าง ๆ แตกต่างกันไปตามการจัดการเรียนรู้และการวัดประเมินผลของผู้สอนดัง Figure 8




Figure 8 แผนภาพผลกระทบจากปัจจัยต่าง ๆ ที่มีต่อความสำเร็จในการเรียนของผู้เรียนแต่ละกลุ่มแยกตามผลลัพธ์การเรียนรู้

3.2 ผลการวิเคราะห์ปัจจัยด้านพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบที่ส่งผลต่อความสำเร็จในการเรียนในระดับรายบุคคลด้วยปัญญาประดิษฐ์ที่อธิบายได้

นอกจากการให้ลำดับความสำคัญของตัวแปรในภาพรวมของโมเดลแล้ว เทคนิค Explainable AI สามารถให้ผลการวิเคราะห์เป็นรายบุคคล ซึ่งผลการวิเคราะห์รายบุคคลของโมเดล Gradient Boosting เป็นการวิเคราะห์โอกาสในการตอบข้อสอบของผู้เรียนแต่ละคนเป็นรายข้อซึ่งจะให้ข้อมูลของปัจจัยที่ทำให้ความสำเร็จในการตอบข้อสอบเปลี่ยนแปลงเพิ่มขึ้นหรือลดลง เมื่อพิจารณาในผู้เรียนคนเดียวกันพบว่าปัจจัยที่ส่งผลต่อการทำข้อสอบแต่ละข้อแตกต่างกันในทำนองเดียวกันเมื่อพิจารณาในข้อสอบข้อเดียวกันแต่เป็นผู้เรียนคนละคนก็พบว่าปัจจัยที่ส่งผลต่อความสำเร็จในการทำข้อสอบมีแตกต่างกันดัง Figure 9




Figure 9 Breakdown Profile ในการทำนายความสำเร็จในการเรียนรายบุคคล

อภิปราย และข้อเสนอแนะ

การอภิปรายจำแนกออกเป็น 2 ส่วน ได้แก่ 1) อภิปรายผลการพัฒนาโมเดลการทำนายความสำเร็จในการเรียนของผู้เรียนด้วยพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบโดยใช้การเรียนรู้ของเครื่อง 2) อภิปรายผลการวิเคราะห์ปัจจัยด้านพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบที่ส่งผลต่อความสำเร็จในการเรียนในระดับภาพรวมและรายบุคคลด้วยปัญญาประดิษฐ์ที่อธิบายได้ รายละเอียดดังนี้

1. อภิปรายผลการพัฒนาโมเดลการทำนายความสำเร็จในการเรียนของผู้เรียนด้วยพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบโดยใช้การเรียนรู้ของเครื่อง

จากผลการสำรวจลักษณะความสำเร็จทางการเรียน พฤติกรรมการเรียนรู้ของผู้เรียน และคุณลักษณะของข้อสอบ พบลักษณะโดยทั่วไปของผู้เรียนกลุ่มนี้จัดเป็นกลุ่มที่มีความสำเร็จทางการเรียนในระดับปานกลางโดยมีผู้เรียนส่วนใหญ่ร้อยละ 58.5 สามารถทำข้อสอบปลายภาคได้ และมีพฤติกรรมในการเรียนรู้ที่ค่อนข้างดี ส่วนข้อสอบปลายภาคทั้ง 80 ข้อ วัดผลลัพธ์การเรียนรู้ครอบคลุมทั้ง 6 ด้านแต่มีสัดส่วนไม่เท่ากันโดยเน้นในด้านการวิเคราะห์และเขียนรายงาน และด้านเครื่องมือและการเก็บข้อมูลส่วนอีก 4 ด้านมีสัดส่วนใกล้เคียงกันอาจเป็นเพราะผลลัพธ์การเรียนรู้ดังกล่าวได้ประเมินแล้วในการสอบกลางภาค นอกจากนี้เมื่อพิจารณาลักษณะความสัมพันธ์ระหว่างตัวแปร ในภาพรวมพบว่ามีความสัมพันธ์ในระดับปานกลางถึงสูงและไม่พบค่าสูญหายในข้อมูล แสดงให้เห็นว่าข้อมูลชุดนี้ค่อนข้างมีความสมบูรณ์แต่มีความซับซ้อน เนื่องจากพบความสัมพันธ์ระหว่างตัวแปรที่ค่อนข้างสูงและชุดข้อมูลมีหน่วยข้อมูลที่แตกต่างกัน ซึ่งลักษณะทั่วไปของชุดข้อมูลในข้างต้นเป็นสิ่งสำคัญที่ใช้ในการพิจารณาเลือกโมเดลการวิเคราะห์ที่เหมาะสม โดยหากพิจารณาแล้วว่าข้อมูลมีความซับซ้อนควรเลือกใช้โมเดลที่สามารถจับความสัมพันธ์ที่ซับซ้อนได้ เพื่อให้ได้ผลการวิเคราะห์ที่ถูกต้อง ไม่เอนเอียง (Holzinger et al., 2022) สอดคล้องกับผลการวิเคราะห์ในส่วนการเปรียบเทียบโมเดลที่พบว่า โมเดล Gradient Boosting เป็นโมเดลที่สามารถทำนายความสำเร็จในการเรียนของผู้เรียนได้อย่างแม่นยำและมีประสิทธิภาพสูงที่สุด อาจเป็นเพราะการปรับค่าพารามิเตอร์ใน Gradient Boosting เช่น จำนวนต้นไม้ (trees) = 500, ความลึกของต้นไม้ (tree_depth) = 10 และ Learning Rate = 0.033 ช่วยให้โมเดลมีเสถียรภาพและสามารถจับความสัมพันธ์ของข้อมูลได้ดี (Hastie et al., 2009) นอกจากนี้ การตั้งค่า sample_size = 0.91 และ stop_iter = 17 ยังช่วยลดโอกาสการเกิด overfitting ขณะที่รักษาประสิทธิภาพสูงสุดไว้ได้ด้วย (Kuhn & Johnson, 2013) เมื่อเปรียบเทียบกับโมเดล Elastic net logistic regression (อันดับ 2) ซึ่งมีค่า ROC_AUC = 0.812 และ Brier Score = 0.176 พบว่า Gradient Boosting มีความโดดเด่นในด้านการทำนายที่แม่นยำมากกว่าโดยเฉพาะในกลุ่มผู้เรียนที่สำเร็จ (Sensitivity) และกลุ่มที่ไม่สำเร็จ (Specificity) ที่มีความสมดุลกว่า ทั้งนี้โมเดลอื่น ๆ เช่น Support Vector Machine (SVM) และ Random Forest ก็มีประสิทธิภาพที่ดีในบางมิติ แต่ยังคงด้อยกว่าตัวชี้วัดโดยรวมของ Gradient Boosting นอกจากนี้เมื่อพิจารณาผลจากโมเดล Neural Network ซึ่งมีประสิทธิภาพต่ำกว่าอาจเป็นเพราะ Neural Network มีข้อจำกัดชัดเจนในบริบทของชุดข้อมูลขนาดเล็กถึงปานกลาง เนื่องจากขนาดข้อมูลไม่เพียงพอต่อการเรียนรู้พารามิเตอร์จำนวนมากในโมเดล ในทางตรงกันข้าม Gradient Boosting แสดงให้เห็นถึงความเหมาะสมและประสิทธิภาพดีกว่า โดยสามารถจับความสัมพันธ์ในข้อมูลและลดโอกาสการ overfitting ได้ดีกว่าโมเดลอื่น ๆ รวมถึงการปรับ Hyperparameters อย่างเหมาะสมช่วยให้โมเดลนี้สามารถสร้างความสมดุลระหว่าง Sensitivity และ Specificity ทำให้เหมาะสมที่สุดสำหรับการนำไปใช้ในงานจริง

อย่างไรก็ตามแม้ Gradient Boosting จะมีประสิทธิภาพสูง แต่ข้อจำกัดของโมเดลคือการนำผลการวิเคราะห์มาอธิบายต่ออาศัยเทคนิค Explainable AI ทำให้การตีความผลลัพธ์โดยตรงเป็นไปได้ยาก (Friedman, 2001) และอาจใช้เทคนิค เช่น SHAP (SHapley Additive exPlanations) หรือ LIME (Local Interpretable Model-Agnostic Explanations) เพื่อเพิ่มความโปร่งใสและรองรับการใช้งานในระบบที่ต้องการคำอธิบาย เช่น ระบบการสนับสนุนการเรียนรู้เชิงปรับตัว (Adaptive Learning Systems) การวิเคราะห์เชิงลึกเหล่านี้ช่วยให้ผู้สอนสามารถออกแบบการเรียนรู้ที่เหมาะสมกับผู้เรียนแต่ละกลุ่มหรือแต่ละบุคคลได้อย่างมีประสิทธิภาพ (Hastie et al., 2009)

2. อภิปรายผลการวิเคราะห์ปัจจัยด้านพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบที่ส่งผลต่อความสำเร็จในการเรียนในระดับภาพรวมและรายบุคคลด้วยปัญญาประดิษฐ์ที่อธิบายได้

เมื่อพิจารณาผลที่ได้จากวิเคราะห์ลำดับความสำคัญของตัวแปร (Feature Importance) ของปัจจัยด้านพฤติกรรมการเรียนรู้และคุณลักษณะของข้อสอบ พบปัจจัยที่ส่งผลต่อความสำเร็จมากที่สุดคือ IRTDiscrimination และ IRTDifficulty รองลงมาคือ ResDesignMid LearningOutcome และ StatMidterm ซึ่งปัจจัยเหล่านี้เกี่ยวข้องกับการวัดประเมินผลการเรียนรู้ของผู้สอนและความรู้ที่มีมาก่อนของผู้เรียน ซึ่งสามารถนำไปใช้ปรับปรุงการจัดการเรียนรู้ในภาพรวมได้ในเบื้องต้น นอกจากนี้เมื่อนำค่าทำนายไปวิเคราะห์จัดกลุ่มและแสดงเป็น Heatmap ดัง Figure 4 ผลการวิเคราะห์แสดงให้เห็นว่าผู้เรียนที่มีรูปแบบการตอบข้อสอบคล้ายคลึงกันจะถูกจัดให้อยู่ในกลุ่มเดียวกัน และสามารถแยกกลุ่มผู้เรียนที่มีศักยภาพสูง (พื้นที่สีฟ้า) ออกจากกลุ่มที่ต้องการการสนับสนุนเพิ่มเติม (พื้นที่สีแดง) ได้อย่างชัดเจน นอกจากนี้ยังสามารถสังเกตความสัมพันธ์ระหว่างคำถามที่มีลักษณะการตอบคล้ายคลึงกัน ซึ่งช่วยให้ระบุได้ว่าข้อสอบบางกลุ่มมีผลต่อการเรียนรู้มากกว่ากลุ่มอื่น ๆ การนำสารสนเทศจาก Heatmap นี้สามารถนำไปสนับสนุนการจัดการเรียนการสอน เช่น การระบุผู้เรียนที่ต้องการการสนับสนุนเพิ่มเติม การปรับปรุงคำถามที่ผู้เรียนส่วนใหญ่ตอบผิด และการจัดกลุ่มผู้เรียนเพื่อพัฒนาเฉพาะกลุ่ม รวมถึงการสร้างระบบแจ้งเตือนล่วงหน้า (Early Warning Systems) สำหรับผู้เรียนที่มีความเสี่ยงต่อการล้มเหลว Heatmap นี้จึงเป็นเครื่องมือสำคัญที่ช่วยให้ผู้สอนและผู้บริหารเข้าใจพฤติกรรมในการตอบข้อสอบของผู้เรียนและนำไปปรับปรุงกระบวนการเรียนการสอนอย่างมีประสิทธิภาพ

เมื่อพิจารณาจากการจัดกลุ่มผู้เรียนตามผลลัพธ์การเรียนรู้โดยใช้ค่า contribution พบว่าปัจจัยที่ส่งผลต่อความสำเร็จในแต่ละกลุ่มมีความแตกต่างกันอย่างชัดเจน สามารถจำแนกผู้เรียนเป็น 3 กลุ่มได้แก่ 1) กลุ่มที่มีแนวโน้มความสำเร็จสูง (HPSG) 2) กลุ่มที่มีแนวโน้มความสำเร็จปานกลาง (MPSG) และ 3) กลุ่มที่มีโอกาสในการพัฒนา (GOG) โดยตัวแปรที่มีค่า contribution สูง ๆ เป็นตัวแปรที่เกี่ยวข้องกับผลการเรียนและภูมิหลังของผู้เรียน เช่น StatMidterm, ResDesignMid ResConceptMid, ResMeasureMid ซึ่งสะท้อนให้เห็นว่า สัดส่วนคะแนนสอบกลางภาคทั้งรายวิชาวิจัยและสถิติส่งผลต่อโอกาสของความสำเร็จในการเรียนรู้ โดยที่ในกลุ่ม HPSG ค่า contribution จะมีค่ามากซึ่งส่งผลเชิงบวกต่อโอกาสของความสำเร็จในการเรียน ในทางตรงข้ามกลุ่ม GOG จะมีค่า contribution น้อย และติดลบทำให้โอกาสของความสำเร็จในการเรียนลดลง ซึ่งสอดคล้องกับการวิเคราะห์ค่าทำนายเป็น 3 กลุ่ม เช่นกัน การวิเคราะห์ในลักษณะนี้สามารถชี้ให้ผู้สอนเห็นถึงปัญหาของผู้เรียนเป็นรายบุคคล เพื่อใช้ข้อมูลในการปรับปรุงและพัฒนาผลสัมฤทธิ์ของผู้เรียนให้เกิดความสำเร็จในการเรียนรู้ได้ เช่น กลุ่ม GOG ต้องการการสนับสนุนเพิ่มเติม ทั้งการสอนเสริม การปรับกิจกรรมการเรียนรู้ และการปรับเปลี่ยนวิธีการประเมินผล ส่วนกลุ่มที่ HPSG สามารถส่งเสริมต่อเนื่องด้วยกิจกรรมที่มีความท้าทาย การจัดกลุ่มนี้ช่วยให้สามารถออกแบบการเรียนการสอนเฉพาะกลุ่มและปรับปรุงกระบวนการประเมินผลได้อย่างเหมาะสมเพื่อเพิ่มประสิทธิภาพการเรียนรู้ในภาพรวม

นอกจากนี้เมื่อพิจารณาการแยกตาม LearningOutcome ทั้ง 6 ด้าน การวิเคราะห์ในลักษณะนี้สามารถชี้ให้ผู้สอนเห็นถึงปัญหาของผู้เรียนและประเมินได้ว่าผู้เรียนมีความคลาดเคลื่อนในมิติใดบ้างเพื่อที่สามารถพัฒนากิจกรรมการเรียนรู้ที่ตรงจุดและสนับสนุนผู้เรียนในแต่ละกลุ่มได้อย่างมีประสิทธิภาพ สามารถจำแนกรูปแบบข้อสอบแต่ละผลลัพธ์การเรียนรู้ตามลักษณะของค่า contribution ในแต่ละกลุ่มของผู้เรียน ออกเป็น 3 รูปแบบ ดังนี้

1. รูปแบบที่ข้อสอบระดับง่าย พบชัดเจนในผลลัพธ์การเรียนรู้ 2 ด้าน ได้แก่ ด้านการประเมินคุณภาพงานวิจัยและด้านการเขียนและพัฒนาโครงการวิจัย เมื่อพิจารณา Figure 8 พบว่า ตัวแปรคุณลักษณะของผู้เรียน เช่น StatMidterm ResDesignMid ResConceptMid ResMeasureMid ResProposeMid ในกลุ่ม HPSG มีค่า contribution เป็นบวกซึ่งส่งผลต่อโอกาสการตอบข้อสอบได้ถูกต้องในผลลัพธ์การเรียนรู้ สำหรับกลุ่ม MPSG และกลุ่ม GOG ก็จะมีค่าลดลงตามลำดับ แต่เมื่อพิจารณาที่ตัวแปร LearningOutcome พบว่า ค่า contribution ของ LearningOutcome เป็นบวกทุกกลุ่ม แสดงให้เห็นว่าผลลัพธ์การเรียนรู้ด้านนี้ไม่ยาก เนื่องจากผู้เรียนทุกกลุ่มมีโอกาสการตอบข้อสอบได้ถูกต้องในผลลัพธ์การเรียนรู้เพิ่มขึ้นสูงสุดสองอันดับแรกจากทั้งหมด 6 ผลลัพธ์การเรียนรู้ซึ่งสอดคล้องกับผลการวิเคราะห์จำแนกกลุ่มที่ค่า contribution ของ LearningOutcome ในเด็กกลุ่ม GOG กลุ่ม MPSG และกลุ่ม HPSG จะได้ค่ามาก กลาง และน้อยตามลำดับ อาจเป็นผลมาจากข้อสอบในผลลัพธ์การเรียนรู้ไม่ยาก และไม่สามารถจำแนกผู้เรียนออกจากกันได้ แม้ไม่จำเป็นต้องมีพื้นฐานความรู้หรืออาจจะไม่ได้เข้าใจในทศน์ที่แท้จริงแต่ยังสามารถทำข้อสอบได้ สอดคล้องกับ MeanDiscrimination ที่ทั้งสองผลลัพธ์การเรียนรู้มีค่าน้อยกว่า -1 ทั้งคู่

2. รูปแบบข้อสอบระดับปานกลาง พบชัดเจนในผลลัพธ์การเรียนรู้ 2 ด้าน ได้แก่ ด้านการวิเคราะห์และการเขียนรายงาน และด้านเครื่องมือและการเก็บข้อมูล จาก Figure 8 พบว่าด้านการวิเคราะห์และการเขียนรายงาน กลุ่ม MPSG จะมีค่า contribution น้อยกว่ากลุ่มอื่น และมีค่าติดลบเป็นส่วนใหญ่ แต่ตัวแปร ResProposeMid ในกลุ่ม MPSG ที่มีค่าติดลบค่อนข้างสูงกว่าของกลุ่ม GOG อาจจะเป็นเพราะผลลัพธ์การเรียนรู้ด้านนี้รวมทักษะการวิเคราะห์ข้อมูลและการเขียนรายงานไว้ด้วยกันซึ่งเป็นเนื้อหาที่ค่อนข้างยาก แต่อย่างไรก็ตามเมื่อพิจารณาในกลุ่ม MPSG พบว่าผลกระทบจากตัวแปร StatMidterm มีค่าสูงกว่าผู้เรียนกลุ่ม GOG ทำให้กลุ่ม MPSG มีโอกาสในการตอบข้อสอบได้ถูกต้องมากกว่า สะท้อนให้เห็นอย่างตรงไปตรงมาว่ากลุ่ม HPSG มีปัจจัยอื่นที่ช่วยเพิ่มโอกาสในการตอบข้อสอบได้ถูกต้อง ในขณะที่กลุ่ม MPSG และกลุ่ม GOG ก็เห็นได้ชัดว่าต้องพัฒนาหรือแก้ไขในปัจจัยด้านใด

3. รูปแบบข้อสอบระดับยาก พบชัดเจนในผลลัพธ์การเรียนรู้ 2 ด้าน ได้แก่ ด้านการออกแบบการวิจัย และด้านมโนทัศน์พื้นฐานการวิจัย จาก Figure 8 พบว่า ในด้านการออกแบบการวิจัยผู้เรียนที่เป็นกลุ่ม HPSG มี contribution ของคะแนนสอบกลางภาคในรายวิชาวิจัยและวิชาสถิติ ค่อนข้างสูง โดยภาพรวมแล้วสูงกว่าผู้เรียนกลุ่ม MPSG และกลุ่ม GOG และผลลัพธ์การเรียนรู้ด้านนี้มี LearningOutcome ของทั้งสามกลุ่มติดลบมากตั้งแต่ -0.688 ถึง -0.508 ซึ่งอาจจะสะท้อนให้เห็นว่า การทำข้อสอบในผลลัพธ์การเรียนรู้นี้เป็นข้อสอบที่ค่อนข้างยาก และมีลักษณะคล้ายคลึงกับด้านมโนทัศน์พื้นฐานการวิจัย นอกจากนี้เมื่อพิจารณาสัดส่วนของการตอบข้อสอบในผลลัพธ์การเรียนรู้ด้านการออกแบบการวิจัยมีสัดส่วนความถูกต้องในการตอบข้อสอบน้อยที่สุดมาเป็นอันดับ 3 และผลลัพธ์การเรียนรู้ด้านมโนทัศน์พื้นฐานการวิจัยมีสัดส่วนการตอบข้อสอบถูกน้อยที่สุด ประมาณร้อยละ 50.9 ซึ่งสอดคล้องกับผลการวิเคราะห์ที่ผู้เรียนทั้งสามกลุ่มมีค่า contribution ในผลลัพธ์การเรียนรู้ทั้งสองด้านติดลบทั้งหมด

นอกจากนี้เมื่อพิจารณาผลการวิเคราะห์รายบุคคลใน Figure 9 แสดงให้เห็นผลกระทบของปัจจัยต่าง ๆ ต่อการนำความสำเร็จของผู้เรียนในแต่ละคนในแต่ละข้อสอบ เช่น ผู้เรียนคนที่ 1 มีโอกาสในการทำข้อสอบข้อที่ 1 ถูกลดลงเป็นร้อยละ 20.9 เนื่องจากมีคะแนนสอบกลางของวิชาสถิติและสารสนเทศการศึกษากับด้านการออกแบบการวิจัยในระดับต่ำ รวมถึงหากข้อสอบมีอำนาจจำแนกต่ำจะยิ่งส่งผลให้มีโอกาสในการตอบถูกลดลงไปอีก นอกจากนี้ยังพบว่าหากเป็น

ข้อสอบในด้านมโนทัศน์พื้นฐานการวิจัยและค่อนข้างง่ายจะทำให้ผู้เรียนมีโอกาสตอบถูกมากขึ้น แต่เมื่อพิจารณาในผู้เรียนคนที่ 3 จะพบว่าในข้อสอบข้อเดียวกันจะได้รับผลกระทบจากปัจจัยด้านข้อสอบใกล้เคียงกันกับผู้เรียนคนที่ 1 ซึ่งมีผลให้ผู้เรียนมีโอกาสในการตอบถูกลดลง แต่พฤติกรรมการเรียนรู้และความสามารถของผู้เรียนคนที่ 3 ส่งผลให้มีโอกาสในการตอบถูกมากขึ้นและมากกว่าผู้เรียนคนที่ 1 เนื่องจากผู้เรียนคนที่ 3 มีคะแนนสอบกลางภาคของวิชาสถิติฯ และคะแนนด้านการออกแบบการวิจัยในระดับสูง จากผลการวิเคราะห์ดังกล่าวสามารถนำไปรายงานผลเป็นรายบุคคลเพื่อให้ผู้เรียนเตรียมตัวได้อย่างเหมาะสมหรือรายงานไปยังผู้สอนเพื่อปรับปรุงการจัดการเรียนการสอนหรือการวัดประเมินที่เหมาะสมต่อไป

ข้อเสนอแนะในการนำผลวิจัยไปใช้

1. นำผลการวิจัยไปออกแบบการเรียนรู้เฉพาะบุคคล (Personalized Learning) ช่วยระบุจุดอ่อนของผู้เรียนรายบุคคล และผู้สอนสามารถจัดการเรียนรู้ที่เสริมจุดแข็งและปรับปรุงจุดอ่อน เช่น จัดกิจกรรมที่เน้นการวิเคราะห์สำหรับผู้เรียนที่มีปัญหากับข้อสอบที่ซับซ้อน
2. ใช้ผลการวิเคราะห์ค่าทำนายในการตอบข้อสอบที่แสดงใน Heatmap เพื่อตรวจสอบข้อสอบที่มีอำนาจจำแนกต่ำหรือความยากที่ไม่เหมาะสม และปรับปรุงคุณภาพของข้อสอบให้ตรงกับผลลัพธ์การเรียนรู้ที่ต้องการ
3. พัฒนาระบบแจ้งเตือนสำหรับผู้เรียนที่อยู่ในกลุ่มที่ต้องการการช่วยเหลือ โดยอ้างอิงจากค่าทำนายความสำเร็จในแต่ละด้าน เพื่อช่วยให้ผู้เรียนและผู้สอนสามารถดำเนินการแก้ไขได้ทันเวลา

ข้อเสนอแนะในการทำวิจัยครั้งต่อไป

1. ขยายการวิเคราะห์ข้อมูลระยะยาว (Longitudinal Study) ติดตามพฤติกรรมการเรียนรู้และผลสัมฤทธิ์ของผู้เรียนในระยะยาว เพื่อวิเคราะห์การเปลี่ยนแปลงและผลกระทบของการปรับปรุงการสอน

References

- Baker, R. S., & Inventado, P. S. (2014). *Educational Data Mining and Learning Analytics*. In J. A. Larusson & B. White (Eds.), *Learning Analytics: From Research to Practice* (pp. 61–75). Springer.
- Gašević, D., Dawson, S., & Siemens, G. (2015). *Let's not forget: Learning analytics are about learning*. *TechTrends*, 59(1), 64–71. DOI: 10.1007/s11528-014-0822-x
- Holzinger, A., Goebel, R., Fong, R., Moon, T., Müller, K.-R., & Samek, W. (2022). *Explainable AI: The new 42 Computers in Industry*, 137, DOI: 10.1016/j.compind.2022.103624
- Kaur, G., Singh, T., & Jain, S. (2022). Personalized Learning: Opportunities and Challenges in the Age of AI. *International Journal of Educational Technology and AI*, 5(2), 45–60.
- Molnar, C. (2020). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. 2nd Edition.
- OECD. (2018). *Future of education and skills 2030: The future we want. Organisation for Economic Co-operation and Development*.
- Office of the Education Council Secretariat. (2021). *Development of Personalized Learning: Learning of the Future*. Bangkok: Office of the Education Council Secretariat.
- Pane, J. F., Steiner, E. D., Baird, M. D., & Hamilton, L. S. (2015). *Continued Progress: Promising Evidence on Personalized Learning*. RAND Corporation.